PREVISIONI AL BUIO

PROGETTO A CURA DI LAURA CAVENATI

CORSO DI STREAMING DATA MANAGEMENT AND TIME SERIES ANALYSIS

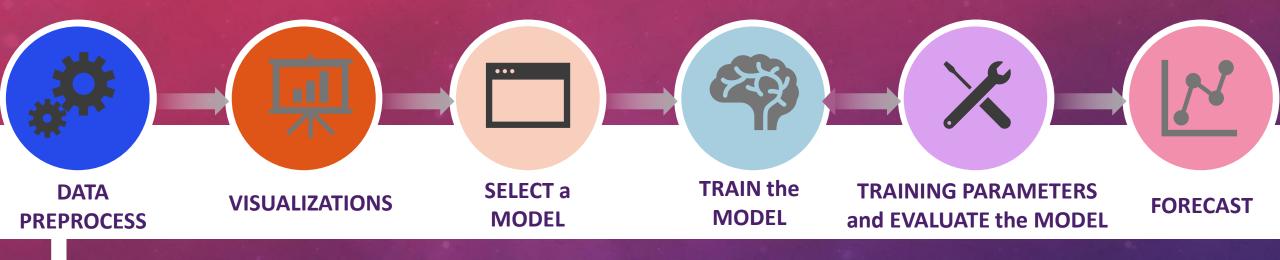
A.A: 2020/2021

LAUREA MAGISTRALE IN DATA SCIENCE

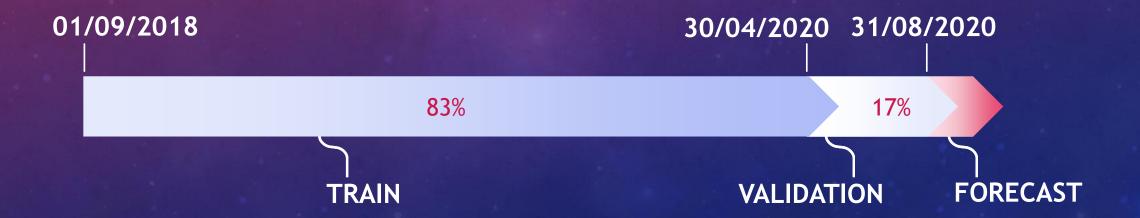
UNIVERSITÀ DEGLI STUDI DI MILANO - BICOCCA



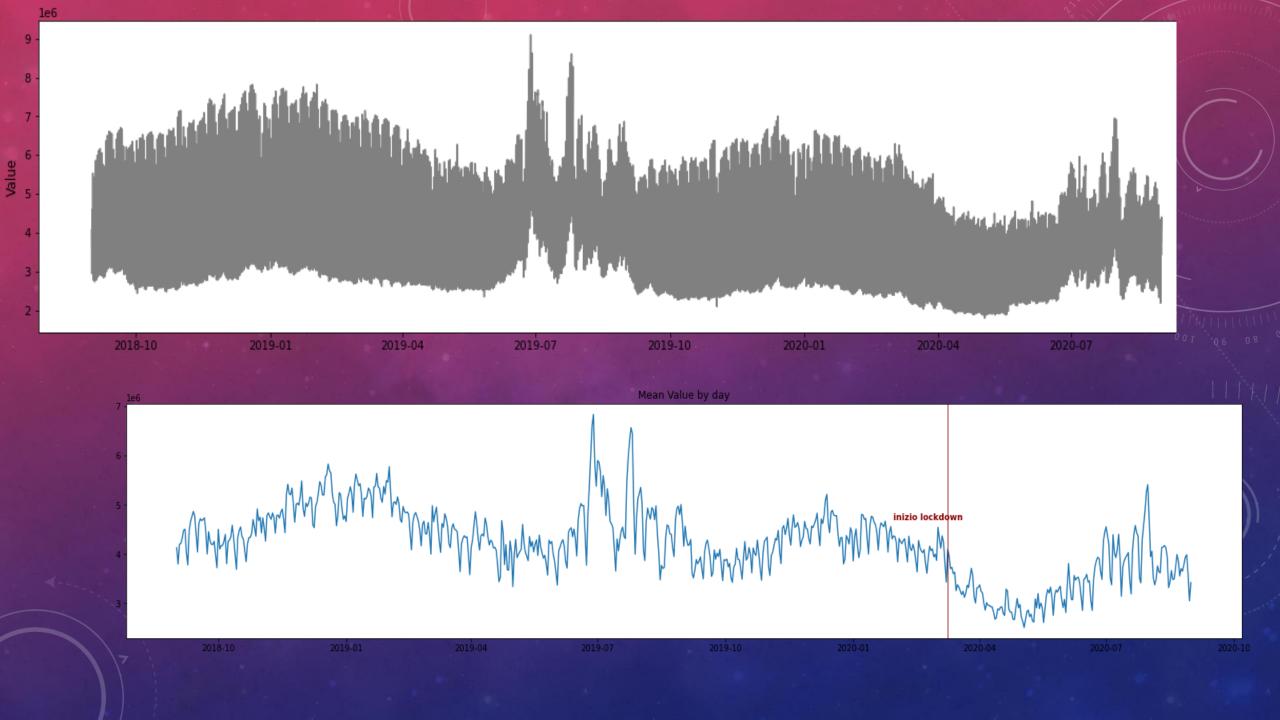
FLOWCHART

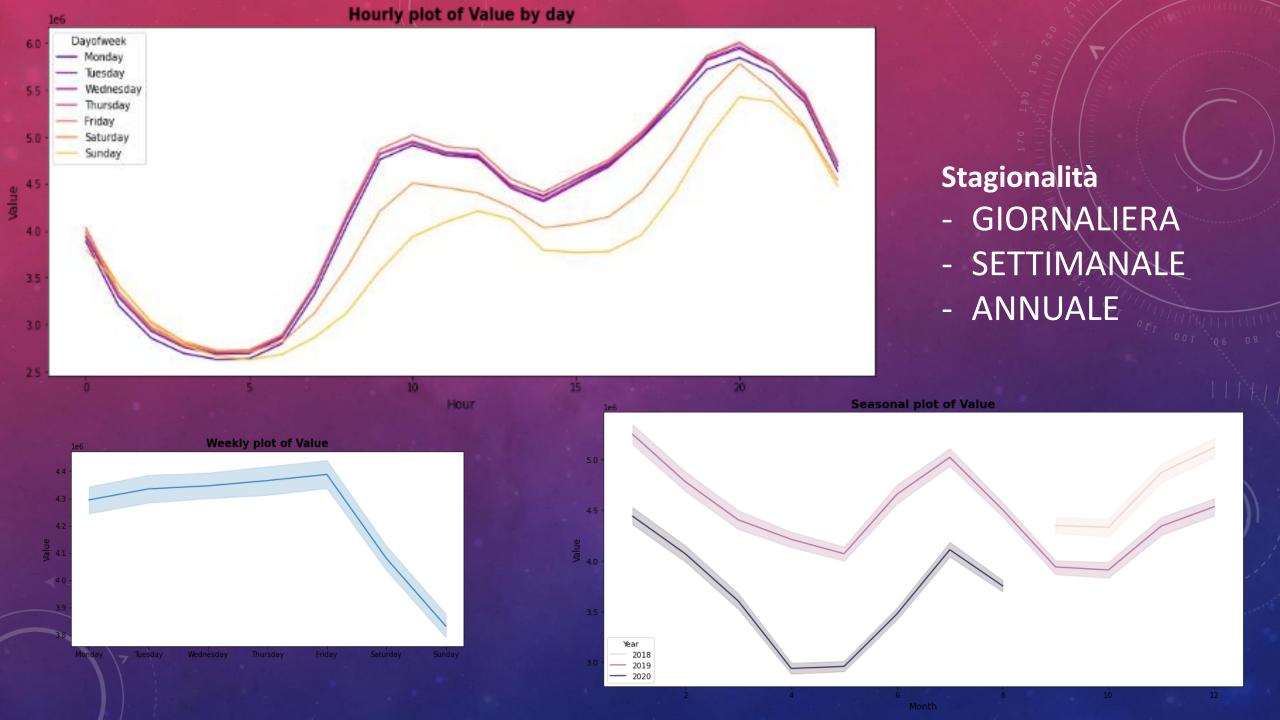


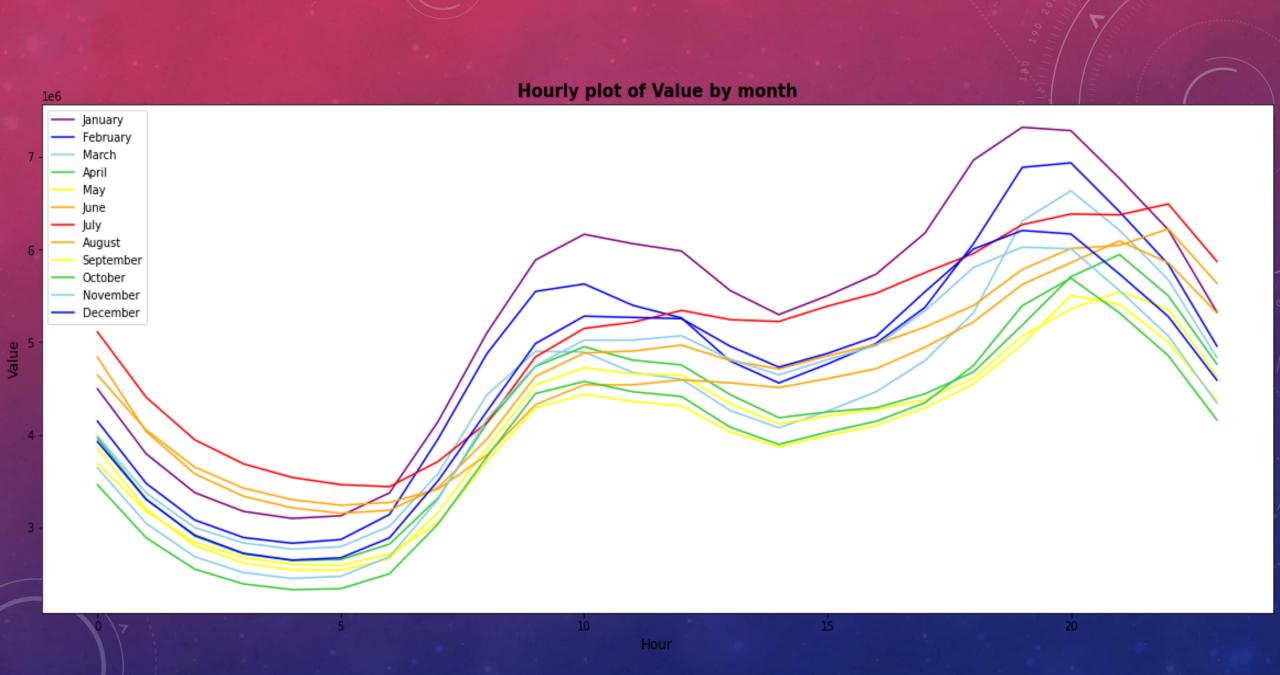
- MISSING VALUES: 2019-03-31 ore 3, 2020-03-29 ore 3 e 2020-05-31
- TRAIN/VALIDATION SPLIT:



VISUALIZZAZIONI INIZIALI



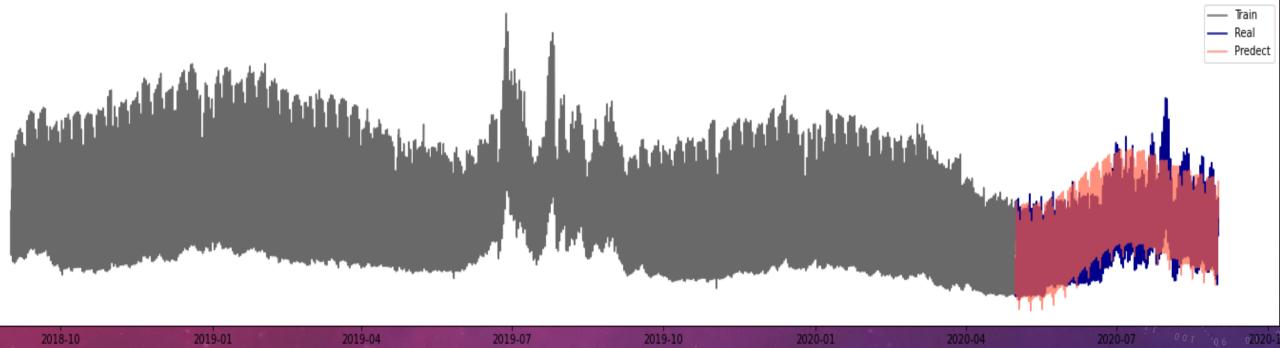




MODELLI



Stazionarietà in varianza LA SERIE è Mean per day vs std per day test **STAZIONARIA?** 1.6 Results of Dickey-Fuller Test: Test Statistic -5.810651e+00 1.4 std per day p-value 4.409576e-07 Lags Used 4.200000e+01 Number of Observations Used 1.454900e+04 Critical Value (1%) -3.430800e+00 Critical Value (5%) -2.861739e+00 Results of KPSS Test: Test Statistic 9.070323 5.5 p-value 0.010000 mean per day Lags Used 42.000000 Critical Value (10%) 0.347000 Critical Value (5%) 0.463000 ACF - 24 Order Diff PACF - 24 Order Diff 0.8 0.8 0.6 0.6 0.4 -0.2 -0.2 -0.2



Miglior modello:

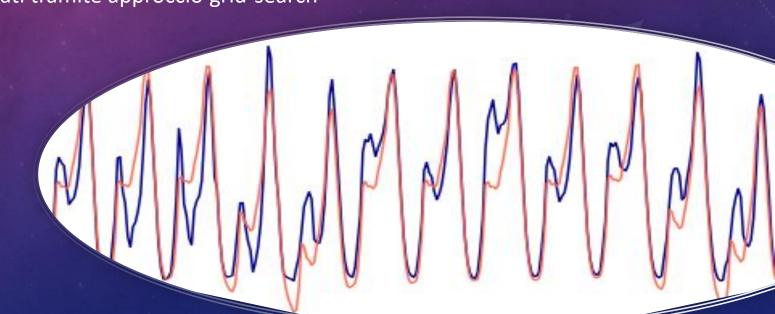
• SARIMAX (2,0,2)(1,1,1)₂₄, parametri determinati tramite approccio grid-search

• stagionalità settimanale: 10 sinusoidi

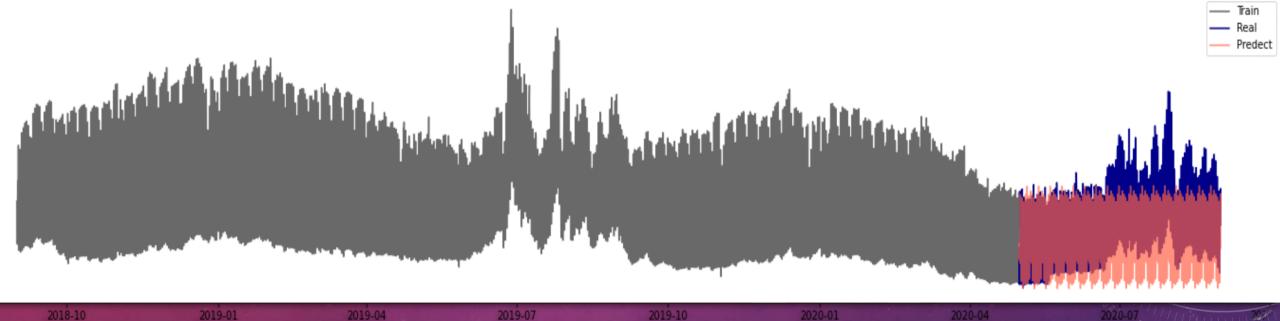
- stagionalità annuale: 5 sinusoidi
- no variabile COVID
- no log-trasformazione
- check sui residui ok

MAE train: 308301.8

MAE validation: 334117.9







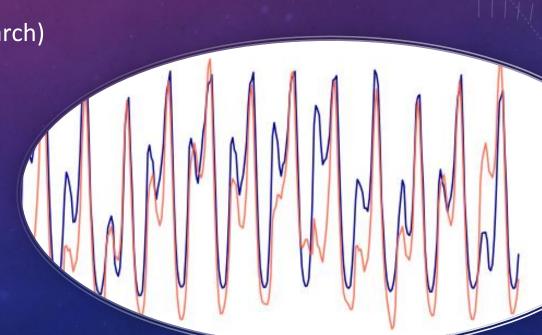
Miglior modello:

trend: random walk (determinato tramite approccio grid-search)

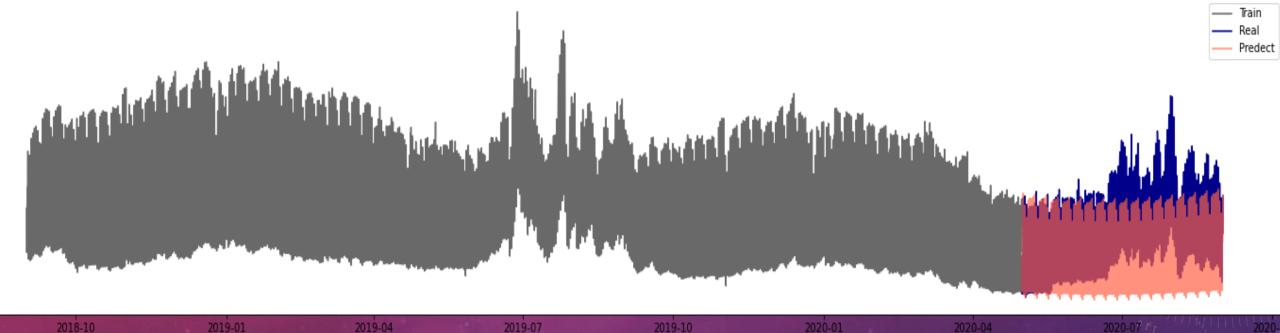
- stagionalità giornaliera: variabili dummy
- stagionalità settimanale: 15 sinusoidi
- no variabile COVID

MAE train: 102623.3

MAE validation: 743458.6





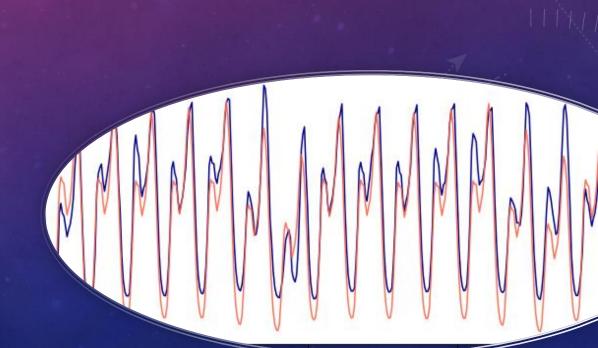


Miglior modello:

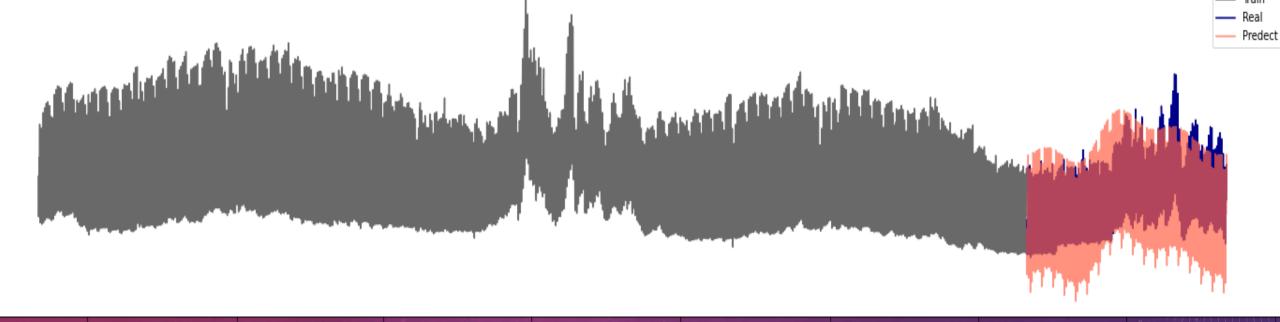
- trasformazione Box-Cox
- modellazione degli errori tramite processo ARMA
- stagionalità multipla con periodo 24, 168 e 8766 ore modellata tramite serie di Fourier.

MAE train: 112372.4

MAE validation: 666606.0







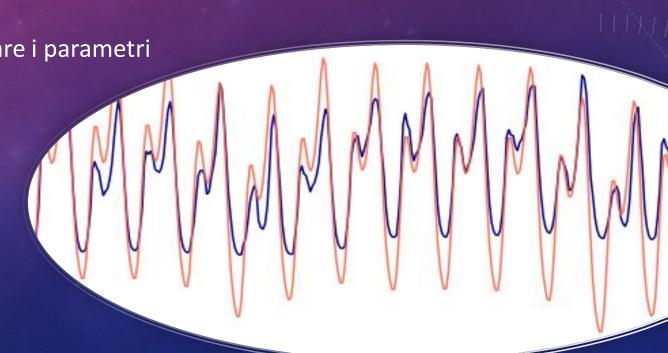
2018-10 2019-01 2019-04 2019-07 2019-10 2020-01 2020-04 2020-07^FF 0 0 F 0 6 0 8

Miglior modello:

- cross-validazione sull'intero dataset per ottimizzare i parametri
- stagionalità giornaliera: 4 sinusoidi
- stagionalità settimanale: 3 sinusoidi
- stagionalità annuale: 10 sinusoidi

MAE train: 366467.4

MAE validation: 545685.0

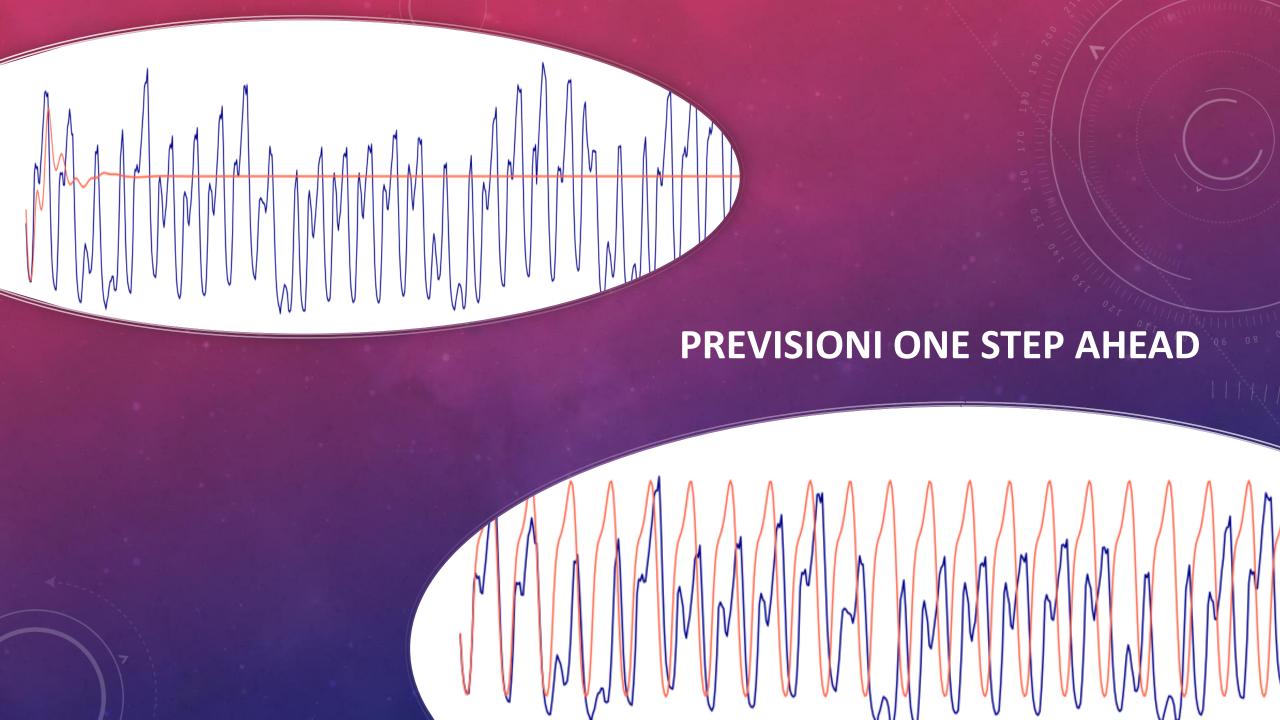


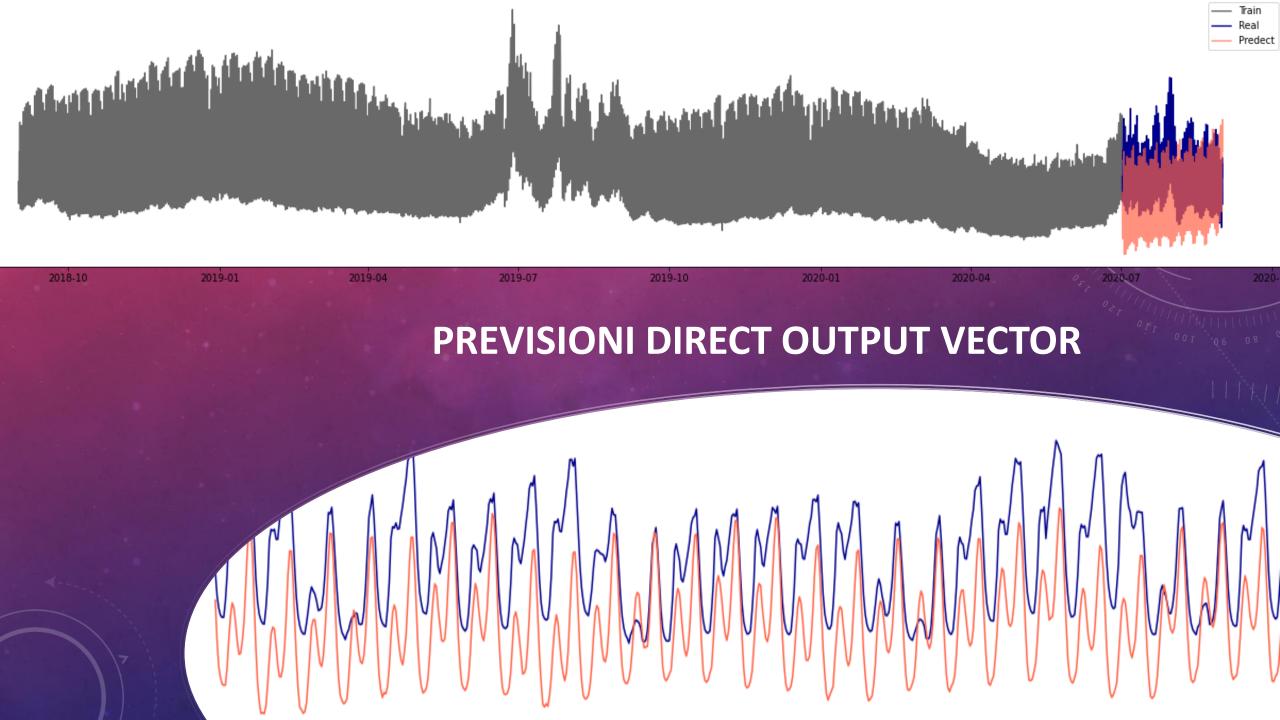


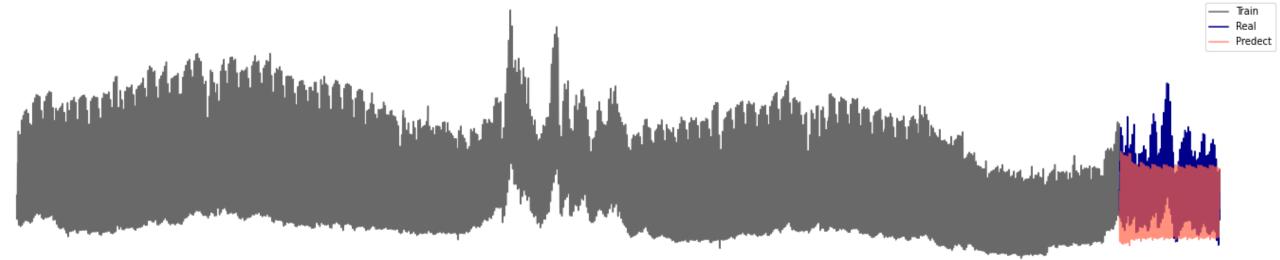
- validation set: ultimi 61 giorni, lunghezza pari alla finestra di forecast
- due diverse implementazioni: stateful e stateless
- tre diverse strategie per le previsioni multi-step:
 - previsioni one-step-ahead
 - previsioni direct output vector
 - previsioni ibride

Layer (type)	Output Shape	Param #
lstm_1 (LSTM)	(None, 100)	40800
leaky_re_lu_1 (LeakyReLU)	(None, 100)	0
dropout_1 (Dropout)	(None, 100)	0
dense_1 (Dense)	(None, 744)	75144

Total params: 115,944 Trainable params: 115,944 Non-trainable params: 0







2019-10

2019-07

2018-10

Miglior modello:

- Number steps in = 24*31
- Number steps out = 24*31
- Modo stateless
- Molto instabile

MAE train: 1077271.0

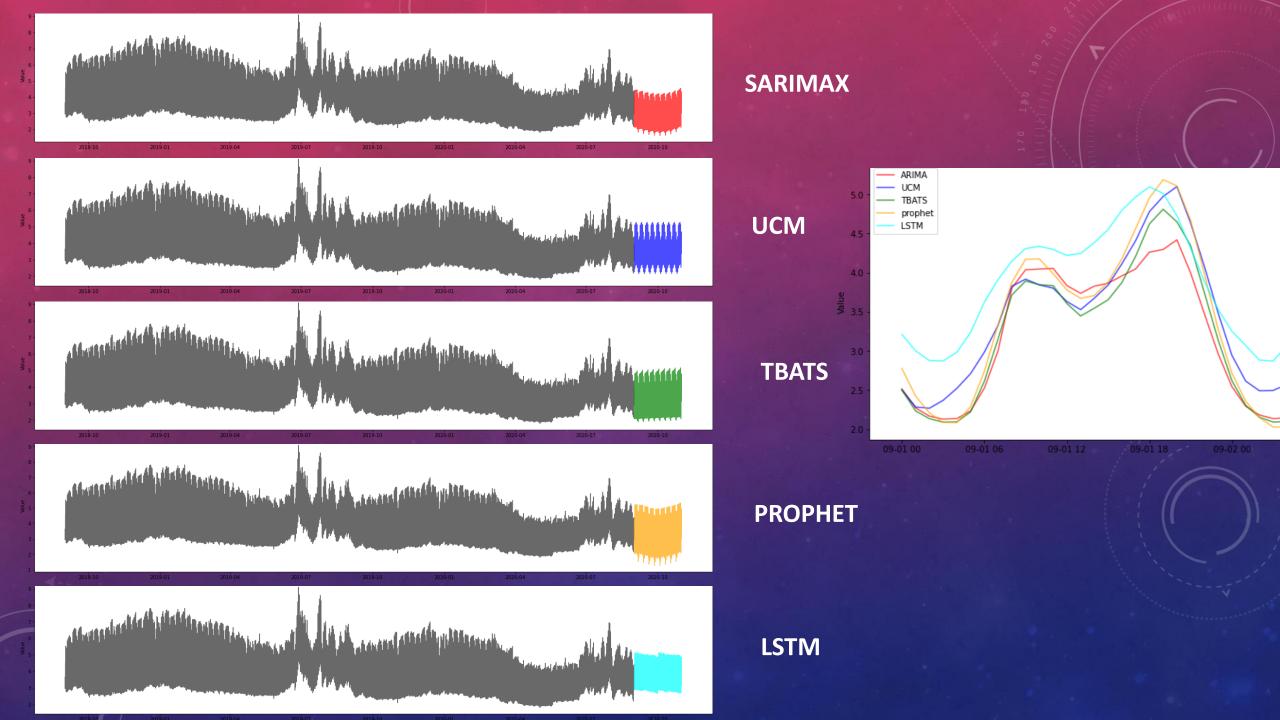
MAE validation 634172.1

PREVISIONI IBRIDE

I modelli provati non sono eccessivamente performanti.

- si potrebbe provare a lavorare con la serie resa stazionaria
- si potrebbero applicare degli aggiustamenti stagionali prima della modellazione

PREVISIONI



CONCLUSIONI E SVILUPPI FUTURI



Il modello SARIMAX risulta il migliore

Per ottenere risultati migliori dovremmo sapere cosa rappresentano i dati.

Sarebbe utile anche conoscere l'andamento della serie negli anni precedenti al 2018 per modellare le anomalie dell'estrae 2019 e il fattore covid in modo più performante.

Come lavoro futuro, i modelli potrebbero essere implementati in un ambiente più potente e con più RAM a disposizione. In tal modo si potrebbero implementare dei metodi per ottimizzare gli iperparametri che altrimenti risultano troppo lenti.



BIBLIOGRAFIA

- http://proceedings.mlr.press/v37/jozefowicz15.pdf
- https://facebook.github.io/prophet/
- https://www.researchgate.net/publication/341609757 Comparative Analysis of Recurrent Neural Network Architectures for Reservoir Inflow Forecasting
- Materiale del corso di Streaming Data Management and Time Series Analysis
- Deep Learning for Time Series Forecasting Predict the Future with MLPs, CNNs and LSTMs in Python,
 Jason Brownlee